Análise de sentimento de textos de avaliação

aplicação para avaliação real time
para plataforma de atendimento

Pré-processamento

Pré Processamento
Remoção de #, @, URL
Remoção de stop words
Conversão de palavras para caixa baixa
Tokenização
Marcação de fala POS
Stemming
Normalização das palavras

sample dos dados

```
num_samples_per_class = 50000  # reshape dos dados, grande dms

df_zero = data[data.polarity == 0.0].sample(num_samples_per_class)
df_one = data[data.polarity == 1.0].sample(num_samples_per_class)

data = pd.concat([df_zero, df_one])

print(data.groupby(['polarity']).size())
```

[4]

```
polarity
0.0    50000
1.0    50000
dtype: int64
```

```
PRE_TRAINED_MODEL_NAME = 'neuralmind/bert-base-portuguese-cased'

tokenizer = BertTokenizer.from_pretrained(PRE_TRAINED_MODEL_NAME)
```

```
token_lens = []

for txt in data.frase:
  tokens = tokenizer.encode_plus(txt,
                                 max_length=512,
                                 truncation=True,
                                 padding='max_length')
  token_lens.append(len(tokens["input_ids"]))
```

```python
class GPReviewDataset(Dataset):

  def __init__(self, reviews, targets, tokenizer, max_len):
    self.reviews = reviews
    self.targets = targets
    self.tokenizer = tokenizer
    self.max_len = max_len

  def __len__(self):
    return len(self.reviews)

  def __getitem__(self, item):
    review = str(self.reviews[item])
    target = self.targets[item]

    encoding = self.tokenizer.encode_plus(
      review,
      add_special_tokens=True,
      max_length=self.max_len,
      truncation=True, # Adicione esta linha se necessário
      return_token_type_ids=False,
      padding='max_length',
      return_attention_mask=True,
      return_tensors='pt',
    )

    return {
      'frase': review,
      'input_ids': encoding['input_ids'].flatten(),
      'attention_mask': encoding['attention_mask'].flatten(),
      'targets': torch.tensor(target, dtype=torch.long)
    }
```

```python
from sklearn.model_selection import train_test_split

# Primeiro, divida data em train e temporary (test + val) datasets
data_train, data_temp = train_test_split(data,
                                         test_size=0.2,
                                         stratify=data['polarity'],
                                         random_state=RANDOM_SEED)

# Em seguida, divida o dataset temporary em test e val datasets
data_val, data_test = train_test_split(data_temp,
                                       test_size=0.5,
                                       stratify=data_temp['polarity'],
                                       random_state=RANDOM_SEED)
```

```
import multiprocessing

num_cores = multiprocessing.cpu_count()
num_workers = min(num_cores, 0)
print(f'Number of available CPU cores: {num_workers}')

def create_data_loader(data, tokenizer, max_len, batch_size):
  ds = GPReviewDataset(
    reviews=data.frase.to_numpy(),
    targets=data.polarity.to_numpy(),
    tokenizer=tokenizer,
    max_len=max_len
  )

  return DataLoader(
    ds,
    batch_size=batch_size,
    num_workers=num_workers
  )
```

Gerando as bases para a relização do treinamento

```
BATCH_SIZE = 16
MAX_LEN = 160
train_data_loader = create_data_loader(data_train, tokenizer, MAX_LEN, BATCH_SIZE)
val_data_loader = create_data_loader(data_val, tokenizer, MAX_LEN, BATCH_SIZE)
test_data_loader = create_data_loader(data_test, tokenizer, MAX_LEN, BATCH_SIZE)

data_valid2 = pd.read_csv('../lexicos/base_validacao.csv')
data_valid2 = data_valid2.dropna(subset=['polarity','frase'])
valid_data_loader2 = create_data_loader(data_valid2, tokenizer, MAX_LEN, BATCH_SIZE)


data_valid = pd.read_csv('../lexicos/base_validacao2.csv')
data_valid = data_valid.dropna(subset=['polarity','frase'])
valid_data_loader = create_data_loader(data_valid, tokenizer, MAX_LEN, BATCH_SIZE)
```

```
dataf = next(iter(train_data_loader))
dataf.keys()
```

```
dict_keys(['frase', 'input_ids', 'attention_mask', 'targets'])
```

```
print(dataf['input_ids'].shape)
print(dataf['attention_mask'].shape)
print(dataf['targets'].shape)
```

```
torch.Size([16, 160])
torch.Size([16, 160])
torch.Size([16])
```

Mascaramento

O sensor de **X1** veio **X2** baterias!

BERT
X1 = umidade
X2 = sem

```python
import torch.nn as nn
class SentimentClassifier(nn.Module):

  def __init__(self, n_classes):
    super(SentimentClassifier, self).__init__()
    self.bert = BertModel.from_pretrained(PRE_TRAINED_MODEL_NAME, return_dict=False)
    self.drop = nn.Dropout(p=0.3)
    self.out = nn.Linear(self.bert.config.hidden_size, n_classes)

  def forward(self, input_ids, attention_mask):
    _, pooled_output = self.bert(
      input_ids=input_ids,
      attention_mask=attention_mask
    )
    output = self.drop(pooled_output)
    return self.out(output)
```

```python
device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print(device)
```

```python
model = SentimentClassifier(2)
model = model.to(device)
```

Treinamento do modelo

Definição do modelo

```
EPOCHS = 10

optimizer = AdamW(model.parameters(), lr=3e-5, correct_bias=False)
total_steps = len(train_data_loader) * EPOCHS

scheduler = get_linear_schedule_with_warmup(
  optimizer,
  num_warmup_steps=0,
  num_training_steps=total_steps
)

loss_fn = nn.CrossEntropyLoss().to(device)
```

```python
def train_epoch(
  model,
  data_loader,
  loss_fn,
  optimizer,
  device,
  scheduler,
  n_examples
):
  model = model.train()

  losses = []
  correct_predictions = 0

  # Aqui estamos usando tqdm para envolver o data_loader e mostrar uma barra de progres
  for d in tqdm(data_loader, desc='Training'):
    input_ids = d["input_ids"].to(device)
    attention_mask = d["attention_mask"].to(device)
    targets = d["targets"].to(device)

    outputs = model(
      input_ids=input_ids,
      attention_mask=attention_mask
    )

    _, preds = torch.max(outputs, dim=1)
    loss = loss_fn(outputs, targets)

    correct_predictions += torch.sum(preds == targets)
    losses.append(loss.item())

    loss.backward()
    nn.utils.clip_grad_norm_(model.parameters(), max_norm=1.0)
    optimizer.step()
    scheduler.step()
    optimizer.zero_grad()

  return correct_predictions.double() / n_examples, np.mean(losses)
```

```python
def eval_model(model, data_loader, loss_fn, device, n_examples):
  model = model.eval()

  losses = []
  correct_predictions = 0

  with torch.no_grad():
    for d in data_loader:
      input_ids = d["input_ids"].to(device)
      attention_mask = d["attention_mask"].to(device)
      targets = d["targets"].to(device)

      outputs = model(
        input_ids=input_ids,
        attention_mask=attention_mask
      )
      _, preds = torch.max(outputs, dim=1)

      loss = loss_fn(outputs, targets)

      correct_predictions += torch.sum(preds == targets)
      losses.append(loss.item())

  return correct_predictions.double() / n_examples, np.mean(losses)
```

```
%%time
from collections import defaultdict
history = defaultdict(list)
best_accuracy = 0

for epoch in range(EPOCHS):

  print(f'Epoch {epoch + 1}/{EPOCHS}')
  print('-' * 10)

  train_acc, train_loss = train_epoch(
    model,
    train_data_loader,
    loss_fn,
    optimizer,
    device,
    scheduler,
    len(data_train)
  )

  print(f'Train loss {train_loss} accuracy {train_acc}')

  val_acc, val_loss = eval_model(
    model,
    val_data_loader,
    loss_fn,
    device,
    len(data_val)
  )
```

```
Epoch 1/10
----------
```

Não foi possível renderizar o conteúdo para "application/vnd.jupyter.widget-view+json"
{"model_id":"503250d916fd4d2793241942cc9712cc","version_major":2,"version_minor":0}

```
Train loss 0.308525221519917 24 accuracy 0.8846375000000001
Val   loss 0.2662830392867327 accuracy 0.903
Valid   loss 0.84 accuracy 0.5752398371696472
Valid 2   loss 0.7567567567567568 accuracy 0.6257485662187848
Test  loss 0.267321840837597 86 accuracy 0.8977
Epoch 2/10
----------
```

Não foi possível renderizar o conteúdo para "application/vnd.jupyter.widget-view+json"
{"model_id":"83a7afd0a1f347cba593a21fe4ef976e","version_major":2,"version_minor":0}

```
Train loss 0.2597990558188409 accuracy 0.912425
Val   loss 0.2882350666642189 accuracy 0.9054000000000001
Valid   loss 0.84 accuracy 0.48558540642261505
Valid 2   loss 0.7207207207207207 accuracy 0.7323708363941738
Test  loss 0.3059738239437342 accuracy 0.8977
Epoch 3/10
```

Ajuste fino do modelo

```
y_review_texts, y_pred, y_pred_probs, y_test = get_predictions(
    model,
    test_data_loader
)
```

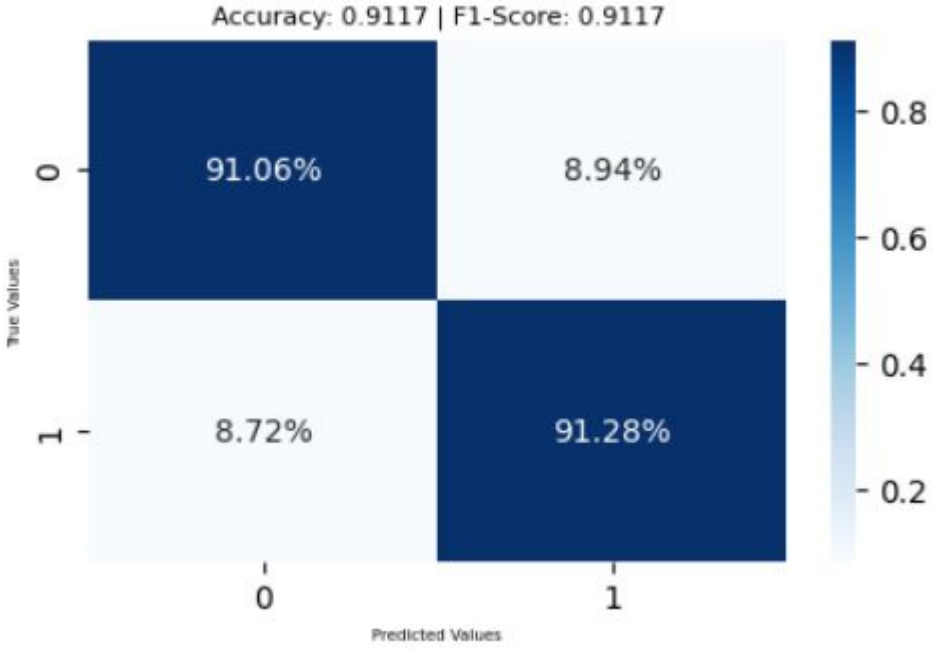

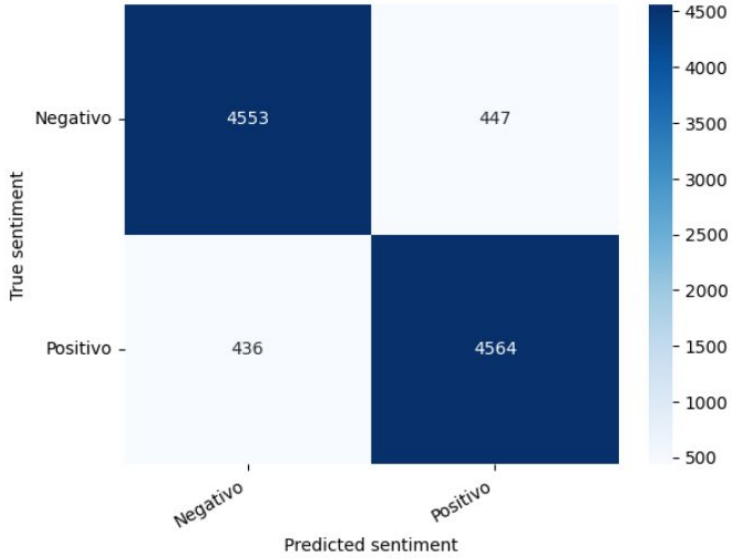

Implantação do modelo

Aplicação do .model a base de mensagens e tela de contatos

```python
# Certifique-se de que o modelo está inicializado
model = SentimentClassifier(len(class_names))
model = model.to(device)

# Carregando o modelo
model.load_state_dict(torch.load(r'D:\Users\heinr\Desktop\TCC-Adriano\classsificação_bert\best_model_state.bin'))
```

```python
import psycopg2
conn = psycopg2.connect(
    host="localhost",
    port=5432,
    user="postgres",
    password="aluno",
    database="projeto_inova"
)

cursor = conn.cursor()
```

```python
import psycopg2

# Conecte-se ao seu banco de dados PostgreSQL
conn = psycopg2.connect(
    host="localhost",
    port=5432,
    user="postgres",
    password="aluno",
    database="projeto_inova"
)
cur = conn.cursor()

# Crie a tabela 'messages'
cur.execute("""
    CREATE TABLE IF NOT EXISTS messages (
        id SERIAL PRIMARY KEY,
        contact_id INT NOT NULL,
        body TEXT,
        created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP
    );
""")

# Confirme as alterações
conn.commit()

# Feche o cursor e a conexão
cur.close()
conn.close()
```

```python
import psycopg2
conn = psycopg2.connect(
    host="localhost",
    port=5432,
    user="postgres",
    password="aluno",
    database="projeto_inova"
)

cursor = conn.cursor()
```

```python
import psycopg2

# Conecte-se ao seu banco de dados PostgreSQL
conn = psycopg2.connect(
    host="localhost",
    port=5432,
    user="postgres",
    password="aluno",
    database="projeto_inova"
)
cur = conn.cursor()

# Crie a tabela 'messages'
cur.execute("""
    CREATE TABLE IF NOT EXISTS contacts (
        contact_id SERIAL PRIMARY KEY,
        phone VARCHAR(15),
        status INT DEFAULT 1
    );
""")

# Confirme as alterações
conn.commit()

# Feche o cursor e a conexão
cur.close()
conn.close()
```

Limpando o Status da contacts

```python
import pandas as pd
import psycopg2

# Conectando ao banco de dados
conn = psycopg2.connect(
    host="localhost",
    port=5432,
    user="postgres",
    password="aluno",
    database="projeto_inova"
)

# Lendo os dados da tabela 'messages' usando Pandas
query = "SELECT * FROM contacts"
df = pd.read_sql(query, conn)

# Feche a conexão
conn.close()

# Agora 'df' contém os dados da tabela 'messages'
print(df)
```

	contact_id	phone	status
0	34507907	62998223865	1
1	32870421	6299385566	1
2	20671831	6299385567	1

```python
import psycopg2

BATCH_SIZE = 16
MAX_LEN = 160

# Conecte-se ao banco de dados PostgreSQL
conn = psycopg2.connect(
    host="localhost",
    port=5432,
    user="postgres",
    password="aluno",
    database="projeto_inova"
)
cur = conn.cursor()

# 1. Recupere todos os IDs únicos de contatos
cur.execute("SELECT DISTINCT contact_id FROM contacts;")
contact_ids = [row[0] for row in cur.fetchall()]
```

```python
for contact_id in contact_ids:
    i += 1
    query = """
        SELECT body FROM messages
        WHERE contact_id = %s
        ORDER BY created_at DESC
        LIMIT 10;
    """
    cur.execute(query, (contact_id,))
    df = pd.read_sql(query, conn, params=(contact_id,))
    df.rename(columns={'body': 'review_text'}, inplace=True)
    df = codigos.preprocess.preprocess_text_stop(df)
    messages = [row[0] for row in cur.fetchall()]

    # Prepare o DataLoader com as 10 mensagens
    valid_data_loader = create_data_loader2(df, tokenizer, MAX_LEN, BATCH_SIZE)

    # 3. Avalie essas mensagens com seu modelo
    y_review_texts_val, y_pred_val, y_pred_probs_val, y_val = get_predictions(model, valid_data_loader)

    df['y_pred'] = y_pred_val
    pd.set_option('display.max_colwidth', None)
    print(df[['frase','y_pred']])

    # 4. Se pelo menos uma previsão for zero, atualize o status do contato
    if any(pred == 0 for pred in y_pred_val):
        cur.execute("UPDATE contacts SET status = 0 WHERE contact_id = %s;", (contact_id,))
    else:
        cur.execute("UPDATE contacts SET status = 1 WHERE contact_id = %s;", (contact_id,))
```

```python
import pandas as pd
import psycopg2

# Conectando ao banco de dados
conn = psycopg2.connect(
    host="localhost",
    port=5432,
    user="postgres",
    password="aluno",
    database="projeto_inova"
)


query = "SELECT * FROM contacts"
df = pd.read_sql(query, conn)

# Feche a conexão
conn.close()

# Agora 'df' contém os dados da tabela 'contacts'
print(df)
```

contatct_id
0

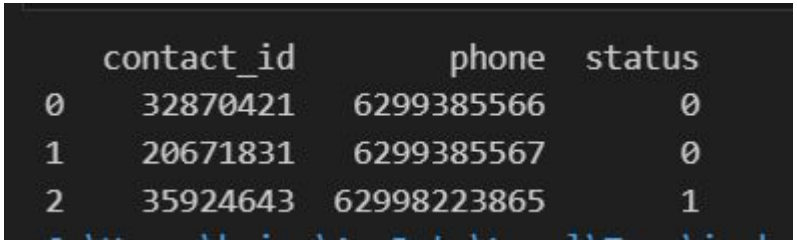

	contact_id	phone	status
0	32870421	6299385566	0
1	20671831	6299385567	0
2	35924643	62998223865	1

	review_text	y_pred
0	Este contato foi editado em 07/02/2023	1
1	Certo! Vou preparar o seu carrinho de compras.	1
3	*Vitor diz:*\n\nNão responda minha mensagem.	0
4	*Vitor diz:*\n\nTem dinheiro para comprar minhas cadeiras	0
5	*Vitor diz:*\n\nOi	1
6	Contato redirecionado para Vitor pelo sistema em 07/02/2023 às 14:55	0
7	1	1
8	Olá, tudo bem\nBem-vindo ao nosso atendimento pelo WhatsApp.\nPara melhor direcioná-lo, digite o número do departamento que deseja falar.\n\n1 - Comercial\n2 - Suporte\n3 - Financeiro	1

contatct_id
1

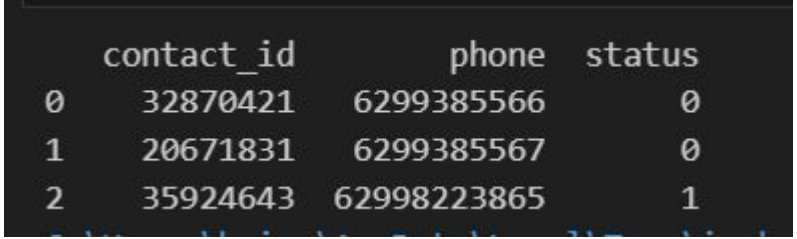

	contact_id	phone	status
0	32870421	6299385566	0
1	20671831	6299385567	0
2	35924643	62998223865	1

	review_text	y_pred
0	*Juscelino diz:*\n\nGrato pelo resposta, qualquer situação, pode nos acionar. Tenha um excelente dia!!!	0
2	Hoje pela manhã está funcionando perfeitamente, obg	1
4	*Juscelino diz:*\n\nBom dia, Leandro. Tudo bem Tivemos um retorno positivo do nosso time técnico em relação a estabilidade da plataforma para hoje. Pode me contar como está a usabilidade hoje para você, por gentileza	1
6	*Luciana Rodrigues diz:*\n\nOlá Leandro, boa tarde! Me chamo Luciana faço parte do Time de Sucesso do Cliente na Poli! Primeiramente gostaria de pedir desculpas em nome da nossa empresa e reforçar com você que já identificamos a causa da instabilidade que afetou o dia de hoje e o nosso time técnico já está operando para retomar a normalização dos serviços. Lamentamos muito o ocorrido e reforçamos que estamos totalmente dedicados em solucionar por completo essa questão. Em breve estaremos operando dentro da normalidade. Qualquer dúvida, estamos aqui para poder te auxiliar!	0
8	NaN	0

contatct_id
2

	contact_id	phone	status
0	32870421	6299385566	0
1	20671831	6299385567	0
2	35924643	62998223865	1

	review_text	y_pred
0	{"body":"Bom dia Nando , tudo bem com você Estou entrando em contato para confirmar nossa reunião prevista para o dia de hoje. Posso confirmar ","header":{"type":"none","text":"","mediaUrl":""},"footer":"","buttons":[],"category":1,"language":46,"name":"polichat_quick_message_359030"}	1
1	Este contato foi editado em 25/05/2023	1
2	*Kennedy Moreira diz:*\n\nMaravilha Nando, te encaminhei o invite	1
3	ok	1
4	*Kennedy Moreira diz:*\n\nVou te enviar o invite da nossa reunião	1
5	*Kennedy Moreira diz:*\n\nBoa tarde Nando	1
6	Contato redirecionado para Kennedy Moreira por Renato Fonseca em 22/05/2023 às 15:31	1
7	*Renato Fonseca diz:*\n\nUm momento	1
8	Preciso falar com o Kenedy	1
9	Souza e Melo Consultoria Previdenciária	1


LOONEY TUNES
"That's all Folks!"